

感知机

Perceptron

- 感知机是二分类线性分类模型，属于判别模型
- 1957年由Rosenblatt提出，是ANN和SVM的基础
 - 输入为实例的特征向量，输出为类别，+1和-1
 - 模型：感知机对应于输入空间中将实例划分为正负两类的分离超平面
 - 策略：使用基于误分类的损失函数；
 - 求解算法：利用SGD对损失函数进行极小化
- 感知机学习分为原始形式和对偶形式

- 定义(感知机)

设输入空间(特征空间)是 $\mathcal{X} \in R^n$, 输出空间是 $\mathcal{Y} = \{+1, -1\}$, 输入 $x \in \mathcal{X}$ 表示样本的特征向量, 对应于输入空间的点, 输出 $y \in \mathcal{Y}$ 表示样本的类别, 由输入空间到输出空间的函数: $f(x) = \text{sign}(w \cdot x + b)$ 称为感知机。


- 模型参数

权值向量 $w \in R^n$, 偏置 b , $w \cdot x$ 是内积
 sign 是符号函数

$$\text{sign}(x) = \begin{cases} +1, & x \geq 0 \\ -1, & x < 0 \end{cases}$$

感知机几何解释

- 线性方程: $w \cdot x + b = 0$
- 对应于特征空间 R^n 的超平面 S , w 为超平面的法向量, b 是超平面的截距, 超平面将特征空间划分为两个部分, 表示正、负类:
- 分离超平面





线性可分数据集

- 给定数据集 $T = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$,
 $x_i \in \mathcal{X} = \mathbb{R}^n$, $y_i \in \mathcal{Y} = \{+1, -1\}$, $i = 1, 2, \dots, N$
- 如果存在某个超平面 S : $w \cdot x + b = 0$, 能够将数据集的正实例点和负实例点完全正确的划分到超平面的两侧, 则称数据集 T 为线性可分数据集 (linearly separable data set)。
- 即:
$$\begin{aligned} w \cdot x_i + b &> 0, & y_i &= +1 \\ w \cdot x_i + b &< 0, & y_i &= -1 \end{aligned}$$

- 对于线性可分数据集，如何定义损失函数？
 - 自然选择：误分类点的数目。
 - 但损失函数不是 w, b 连续可导函数，不易优化
 - 另一选择：误分类点到超平面S的总距离：
- R^n 中任意一点 x_0 到超平面S的距离： $\frac{1}{\|w\|} |w \cdot x_0 + b|$
- 对于误分类点 (x_i, y_i) ，有 $-y_i(w \cdot x_i + b) > 0$
- 则：误分类 x_i 点到S的距离： $-\frac{1}{\|w\|} y_i(w \cdot x_i + b)$
- 误分类点集合M, 所有误分类到S的总距离

$$-\frac{1}{\|w\|} \sum_{x_i \in M} y_i(w \cdot x_i + b)$$

- 损失函数：

- 不考虑 $\frac{1}{\|w\|}$ ，得到感知机学习的损失函数

$$L(w, b) = - \sum_{x_i \in M} y_i (w \cdot x_i + b)$$

- M为误分类点的数目
- 该损失函数就是感知机的经验风险函数
- 如果没有误分类点， $L=0$
- 误分类点越少，误分类点离超平面S越近，损失函数值越小

- 给定数据集 $T = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$,
 $x_i \in \mathcal{X} = R^n$, $y_i \in \mathcal{Y} = \{+1, -1\}$, $i = 1, 2, \dots, N$,
求参数 w, b , 使其为损失函数极小化问题的解

$$\min_{w, b} L(w, b) = - \sum_{x_i \in M} y_i (w \cdot x_i + b)$$

M 为误分类点的数目。

$$\min_{w, b} L(w, b) = - \sum_{x_i \in M} y_i (w \cdot x_i + b)$$

- 采用SGD求解: 首先任意选择一个超平面 w_0, b_0 , 然后不断极小化目标函数, 损失函数 L 的梯度:

$$\nabla_w L(w, b) = - \sum_{x_i \in M} y_i x_i$$

$$\nabla_b L(w, b) = - \sum_{x_i \in M} y_i$$

- 选取误分类点 (x_i, y_i) 更新:

$$w \leftarrow w + \eta y_i x_i$$

$$b \leftarrow b + \eta y_i$$

$\eta (0 < \eta \leq 1)$ 是学习率。

感知机学习算法（原始形式）

输入：训练数据集 $T = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$,
其中 $x_i \in \mathcal{X} = \mathbf{R}^n$, $y_i \in \mathcal{Y} = \{+1, -1\}$, $i = 1, 2, \dots, N$, 学
习率 $\eta (0 < \eta \leq 1)$;

输出： w, b ; 感知机模型 $f(x) = \text{sign}(w \cdot x + b)$

(1) 选取初值 w_0, b_0

(2) 在训练集中选取数据 (x_i, y_i)

(3) 如果 $y_i(w \cdot x_i + b) \leq 0$,

$$w \leftarrow w + \eta y_i x_i$$

$$b \leftarrow b + \eta y_i$$

(4) 转至 (2), 直至训练集中没有误分类点。

例 2.1 如图 2.2 所示的训练数据集，其正实例点是 $x_1 = (3,3)^T$ ， $x_2 = (4,3)^T$ ，负实例点是 $x_3 = (1,1)^T$ ，试用感知机学习算法的原始形式求感知机模型 $f(x) = \text{sign}(w \cdot x + b)$ ，这里， $w = (w^{(1)}, w^{(2)})^T$ ， $x = (x^{(1)}, x^{(2)})^T$




图 2.2 感知机示例

解：构建优化问题 $\min_{w,b} L(w, b) = -\sum_{x_i \in M} y_i (w \cdot x_i + b)$

求解： $w, b, \eta = 1$

(1) 选取初值 $w_0 = 0; b_0 = 0$

(2) 对于 $x_1 = (3, 3)^T$, $y_1(w_0 \cdot x_1 + b_0) = 0$, 没有正确分类, 更新 w, b

$$w_1 = w_0 + y_1 x_1 = (3, 3)^T, \quad b_1 = b_0 + y_1 = 1$$

得线性模型： $w_1 \cdot x + b_1 = 3x^{(1)} + 3x^{(2)} + 1$

(3) 对于 x_1, x_2 , $y_i(w_1 \cdot x_i + b_1) > 0$, 分类正确。

对于 $x_3 = (1, 1)^T$, $y_3(w_1 \cdot x_3 + b_1) = -7 < 0$, 误分类, 更新 w, b

$$w_2 = w_1 + y_3 x_3 = (2, 2)^T, \quad b_2 = b_1 + y_3 = 0$$

得到线性模型： $w_2 \cdot x + b_2 = 2x^{(1)} + 2x^{(2)}$

继续迭代得到： $w_7 = (1, 1)^T, b_7 = -3$,

$$w_7 \cdot x + b_7 = x^{(1)} + x^{(2)} - 3$$

所有数据分类正确, 损失函数最小。

感知机学习算法 举例

- 分离超平面为

$$x^{(1)} + x^{(2)} - 3 = 0$$

- 感知机模型为 $f(x) = \text{sign}(x^{(1)} + x^{(2)} - 3)$

表 2.1 例 2.1 求解的迭代过程

迭代次数	误分类点	w	b	$w \cdot x + b$
0		0	0	0
1	x_1	$(3,3)^T$	1	$3x^{(1)} + 3x^{(2)} + 1$
2	x_3	$(2,2)^T$	0	$2x^{(1)} + 2x^{(2)}$
3	x_3	$(1,1)^T$	-1	$x^{(1)} + x^{(2)} - 1$
4	x_3	$(0,0)^T$	-2	-2
5	x_1	$(3,3)^T$	-1	$3x^{(1)} + 3x^{(2)} - 1$
6	x_3	$(2,2)^T$	-2	$2x^{(1)} + 2x^{(2)} - 2$
7	x_3	$(1,1)^T$	-3	$x^{(1)} + x^{(2)} - 3$
8	0	$(1,1)^T$	-3	$x^{(1)} + x^{(2)} - 3$

选取不同的初值和不同的误分类点，感知机解可能不同

- 算法的收敛性：证明经过**有限次迭代**可以得到一个将训练数据集完全正确划分的分离超平面及感知机模型。

将 b 并入权重向量 w ，记作：

$$\hat{w} = (w^T, b)^T$$

令 $x_0 = 1$ ，有 $\hat{x} = (x^T, 1)^T$ ， $\hat{x} \in R^{n+1}$ $\hat{w} \in R^{n+1}$

有： $\hat{w} \cdot \hat{x} = w \cdot x + b$

算法的收敛性

- Novikoff定理

训练集 $T = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$ 是线性可分的, 其中 $x_i \in \mathcal{X} = \mathbf{R}^n$, $y_i \in \mathcal{Y} = \{+1, -1\}$, $i = 1, 2, \dots, N$ 则

(1) 存在满足条件 $\|\hat{\mathbf{w}}_{opt}\| = 1$ 的超平面 $\hat{\mathbf{w}}_{opt} \cdot \hat{\mathbf{x}} = \mathbf{w}_{opt} \cdot \mathbf{x} + b_{opt} = 0$, 将训练数据集完全正确分开; 且存在 γ , 对所有 $i = 1, 2, \dots, N$

$$y_i (\hat{\mathbf{w}}_{opt} \cdot \hat{\mathbf{x}}) = y_i (\mathbf{w}_{opt} \cdot \mathbf{x} + b_{opt}) \geq \gamma$$

(2) 令 $R = \max_{1 \leq i \leq N} \|\hat{\mathbf{x}}_i\|$, 则感知机算法在训练数据集上的误分类次数 K 满足不等式

$$K \leq \left(\frac{R}{\gamma} \right)^2$$

证明：(1)

由线性可分，存在超平面

$$\hat{\mathbf{w}}_{opt} \cdot \hat{\mathbf{x}} = \mathbf{w}_{opt} \cdot \mathbf{x} + \mathbf{b}_{opt} = 0, \text{ 使 } \|\hat{\mathbf{w}}_{opt}\| = 1,$$

对于有限个点 $i = 1, 2, \dots, N$ 均有：

$$y_i (\hat{\mathbf{w}}_{opt} \cdot \hat{\mathbf{x}}) = y_i (\mathbf{w}_{opt} \cdot \mathbf{x} + \mathbf{b}_{opt}) \geq 0$$

所以存在 $\gamma = \min_i \{y_i (\mathbf{w}_{opt} \cdot \mathbf{x} + \mathbf{b}_{opt})\}$

使得：

$$y_i (\hat{\mathbf{w}}_{opt} \cdot \hat{\mathbf{x}}) = y_i (\mathbf{w}_{opt} \cdot \mathbf{x} + \mathbf{b}_{opt}) \geq \gamma$$

证明：(2)

证明：由于感知机算法从 $\hat{\mathbf{w}}_0 = 0$ 开始，则，令 $\hat{\mathbf{w}}_{k-1}$ 是第k个误分类实例之前的扩充权值向量，即

$$\hat{\mathbf{w}}_{k-1} = (\mathbf{w}_{k-1}^T, \mathbf{b}_{k-1})^T$$

第k个误分类实例的条件是：

$$\mathbf{y}_i (\hat{\mathbf{w}}_{k-1} \cdot \hat{\mathbf{x}}_i) = \mathbf{y}_i (\mathbf{w}_{k-1} \cdot \mathbf{x}_i + \mathbf{b}_{k-1}) \leq 0$$

则w和b的更新：

$$\begin{aligned}\mathbf{w}_k &\leftarrow \mathbf{w}_{k-1} + \eta \mathbf{y}_i \mathbf{x}_i \\ \mathbf{b}_k &\leftarrow \mathbf{b}_{k-1} + \eta \mathbf{y}_i\end{aligned}$$

即：

$$\hat{\mathbf{w}}_k = \hat{\mathbf{w}}_{k-1} + \eta \mathbf{y}_i \hat{\mathbf{x}}_i$$

Novikoff定理

推导两个不等式:

$$1) \hat{\mathbf{w}}_k \cdot \hat{\mathbf{w}}_{opt} \geq k\eta\gamma$$

$$\text{由: } \hat{\mathbf{w}}_k = \hat{\mathbf{w}}_{k-1} + \eta y_i \hat{\mathbf{x}}_i$$

$$\text{及 } y_i (\hat{\mathbf{w}}_{opt} \cdot \hat{\mathbf{x}}) = y_i (\mathbf{w}_{opt} \cdot \mathbf{x} + b_{opt}) \geq \gamma$$

得:

$$\begin{aligned} \hat{\mathbf{w}}_k \cdot \hat{\mathbf{w}}_{opt} &= \hat{\mathbf{w}}_{k-1} \cdot \hat{\mathbf{w}}_{opt} + \eta y_i \hat{\mathbf{w}}_{opt} \hat{\mathbf{x}}_i \\ &\geq \hat{\mathbf{w}}_{k-1} \cdot \hat{\mathbf{w}}_{opt} + \eta\gamma \end{aligned}$$

由此递推得:

$$\hat{\mathbf{w}}_k \cdot \hat{\mathbf{w}}_{opt} \geq \hat{\mathbf{w}}_{k-1} \cdot \hat{\mathbf{w}}_{opt} + \eta\gamma \geq \hat{\mathbf{w}}_{k-2} \cdot \hat{\mathbf{w}}_{opt} + 2\eta\gamma \geq k\eta\gamma$$

Novikoff定理

推导两个不等式:

$$2) \|\hat{\mathbf{w}}_k\|^2 \leq k\eta^2 R^2$$

由

$$y_i (\hat{\mathbf{w}}_{k-1} \cdot \hat{\mathbf{x}}_i) = y_i (\mathbf{w}_{k-1} \cdot \mathbf{x}_i + b_{k-1}) \leq 0$$

以及

$$\hat{\mathbf{w}}_k = \hat{\mathbf{w}}_{k-1} + \eta y_i \hat{\mathbf{x}}_i$$

得:

误分类点

$$\|\hat{\mathbf{w}}_k\|^2 = \|\hat{\mathbf{w}}_{k-1}\|^2 + 2\eta y_i \hat{\mathbf{w}}_{k-1} \cdot \hat{\mathbf{x}}_i + \eta^2 \|\hat{\mathbf{x}}_i\|^2$$

$$\leq \|\hat{\mathbf{w}}_{k-1}\|^2 + \eta^2 \|\hat{\mathbf{x}}_i\|^2$$

$$\leq \|\hat{\mathbf{w}}_{k-1}\|^2 + \eta^2 R^2$$

$$R = \max_{1 \leq i \leq N} \|\hat{\mathbf{x}}_i\|$$

$$\leq \|\hat{\mathbf{w}}_{k-2}\|^2 + 2\eta^2 R^2 \leq \dots$$

$$\leq k\eta^2 R^2$$

Novikoff定理

结合两个不等式,

$$\begin{aligned}\hat{\mathbf{w}}_k \cdot \hat{\mathbf{w}}_{opt} &\geq k\eta\gamma \\ \|\hat{\mathbf{w}}_k\|^2 &\leq k\eta^2 R^2\end{aligned}$$

得

$$k\eta\gamma \leq \hat{\mathbf{w}}_k \cdot \hat{\mathbf{w}}_{opt} \leq \|\hat{\mathbf{w}}_k\| \|\hat{\mathbf{w}}_{opt}\| \leq \sqrt{k\eta} R$$


$$k^2 \gamma^2 \leq kR^2$$

$$\|\hat{\mathbf{w}}_{opt}\| = 1$$

得

$$K \leq \left(\frac{R}{\gamma}\right)^2$$

- 定理表明：
 - 误分类的次数 k 是有上界的，当训练数据集线性可分时，感知机学习算法原始形式迭代是收敛的。
- 感知机算法存在许多解，既依赖于初值，也依赖迭代过程中误分类点的选择顺序。
- 为得到唯一分离超平面，需要增加约束，如SVM
- 线性不可分数据集，迭代震荡。



感知机算法的对偶形式

- 基本想法：将 w 和 b 表示为实例 x_i 和标记 y_i 的线性组合的形式，通过求解其系数而求得 w 和 b 。
- 对误分类点 (x_i, y_i) ：

$$w \leftarrow w + \eta y_i x_i, \quad b \leftarrow b + \eta y_i$$

设修改 n 次, $n = \sum_{i=1}^N n_i$,

则 w, b 关于 (x_i, y_i) 的增量分别是 $\alpha_i y_i x_i$ 和 $\alpha_i y_i$,

$\alpha_i = n_i \eta$, (n_i 是 α_i 修改的次数)

于是：

$$w = \sum_{i=1}^N \alpha_i y_i x_i \quad b = \sum_{i=1}^N \alpha_i y_i$$

$$\alpha_i \geq 0, \quad i = 1, 2, \dots, N$$

感知机算法的对偶形式

感知机学习算法(对偶形式)：

输入：

线性可分训练数据集 $T = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$,
其中 $x_i \in \mathcal{X} = \mathbf{R}^n$, $y_i \in \mathcal{Y} = \{+1, -1\}$, $i = 1, 2, \dots, N$, 学习
率 $\eta (0 < \eta \leq 1)$;

输出： α, b ；感知机模型

$$f(x) = \text{sign}\left(\sum_{j=1}^N \alpha_j y_j x_j \cdot x + b\right)$$

其中, $\alpha = (\alpha_1, \alpha_2, \dots, \alpha_N)^T$

感知机算法的对偶形式

(1) 选取初值 $\alpha \leftarrow \mathbf{0}, b \leftarrow 0$

(2) 在训练集中选取数据 (x_i, y_i)

(3) 如果 $y_i(\sum_{j=1}^N \alpha_j y_j x_j \cdot x_i + b) \leq 0$,

$$\alpha_i \leftarrow \alpha_i + \eta$$

$$b \leftarrow b + \eta y_i$$

(4) 转至 (2)，直至训练集中没有误分类点。

- **Gram矩阵**: 训练实例仅以内积的形式出现，可以预先计算，存储为矩阵形式。

$$G = [x_i \cdot x_j]_{N \times N}$$

感知机算法的对偶形式 举例

用感知机算法（对偶形式）求解感知机模型：

数据同前一个例子，正样本点是 $x_1 = (3, 3)^T$, $x_2 = (4, 3)^T$,
负样本点 $x_3 = (1, 1)^T$ 。

解：

(1) 取 $\alpha_i = 0, i = 1, 2, 3, b = 0, \eta = 1$

(2) 计算Gram矩阵

$$G = \begin{bmatrix} 18 & 21 & 6 \\ 21 & 25 & 7 \\ 6 & 7 & 2 \end{bmatrix}$$

(3) 误分条件 $y_i (\sum_{j=1}^N \alpha_j y_j x_j \cdot x_i + b) \leq 0$,

参数更新, $\alpha_i \leftarrow \alpha_i + 1, b \leftarrow b + y_i$

(4) 迭代。

感知机算法的对偶形式 举例

误分条件 $y_i(\sum_{j=1}^N \alpha_j y_j x_j \cdot x_i + b) \leq 0$

参数更新, $\alpha_i \leftarrow \alpha_i + 1, b \leftarrow b + y_i$

Step 1:

$$y_1(\sum_{j=1}^N \alpha_j y_j x_j \cdot x_1 + b) = 1(0 + 0 + 0 + 0) = 0$$

(x_1, y_1) 满足误分类条件, 更新 $\alpha_1 = 0 + 1 = 1, b = 0 + 1 = 1$

Step 2:

$$y_1(\sum_{j=1}^N \alpha_j y_j x_j \cdot x_1 + b) = 1(1 \cdot 1 \cdot 18 + 0 + 0 + 1) = 19$$

$$y_2(\sum_{j=1}^N \alpha_j y_j x_j \cdot x_2 + b) = 1(1 \cdot 1 \cdot 21 + 0 + 0 + 1) = 22$$

$$y_3(\sum_{j=1}^N \alpha_j y_j x_j \cdot x_3 + b) = -1(1 \cdot 1 \cdot 6 + 0 + 0 + 1) = -7$$

(x_3, y_3) 满足误分类条件, 更新 $\alpha_3 = 0 + 1 = 1, b = 1 - 1 = 0$

感知机算法的对偶形式 举例

Step 3:

$$y_1(\sum_{j=1}^N \alpha_j y_j x_j \cdot x_1 + b) = 1(1 \cdot 1 \cdot 18 + 0 + 1 \cdot 1 \cdot 6 + 0) = 24$$

$$y_2(\sum_{j=1}^N \alpha_j y_j x_j \cdot x_2 + b) = 1(1 \cdot 1 \cdot 21 + 0 + 1 \cdot 1 \cdot 7 + 0) = 28$$

$$y_3(\sum_{j=1}^N \alpha_j y_j x_j \cdot x_3 + b) = -1(1 \cdot 1 \cdot 6 + 0 + 1 \cdot 1 \cdot 2 + 0) = -8$$

(x_3, y_3) 满足条件, 更新 $\alpha_3 = 1 + 1 = 2$, $b = 0 - 1 = -1$

Step 4:

$$y_1(\sum_{j=1}^N \alpha_j y_j x_j \cdot x_1 + b) = 1(1 \cdot 1 \cdot 18 + 0 + 2 \cdot 1 \cdot 6 - 1) = 29$$

$$y_2(\sum_{j=1}^N \alpha_j y_j x_j \cdot x_2 + b) = 1(1 \cdot 1 \cdot 21 + 0 + 2 \cdot 1 \cdot 7 - 1) = 34$$

$$y_3(\sum_{j=1}^N \alpha_j y_j x_j \cdot x_3 + b) = -1(1 \cdot 1 \cdot 6 + 0 + 2 \cdot 1 \cdot 2 - 1) = -9$$

(x_3, y_3) 满足条件, 更新 $\alpha_3 = 2 + 1 = 3$, $b = -1 - 1 = -2$

...

迭代过程见表格。

k	0	1	2	3	4	5	6	7
		x_1	x_3	x_3	x_3	x_1	x_3	x_3
α_1	0	1	1	1	1	2	2	2
α_2	0	0	0	0	0	0	0	0
α_3	0	0	1	2	3	3	4	5
b	0	1	0	-1	-2	-1	-2	-3

$$(5) \quad w = \sum_{i=1}^N \alpha_i y_i x_i = 2x_1 + 0x_2 - 5x_3 = 2 \begin{pmatrix} 3 \\ 3 \end{pmatrix} - 5 \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \end{pmatrix} = (1, 1)^T$$

$$b = -3$$

分离超平面 $x^{(1)} + x^{(2)} - 3 = 0$

感知机模型 $f(x) = \text{sign}(x^{(1)} + x^{(2)} - 3)$